1. IDENTIFICACIÓN DE LA GUÍA

Nombre de la guía:	Despliegue de modelo detector de objetos
Código de la guía (No.):	004
Taller(es) o Laboratorio(s) aplicable(s):	Laboratorio O
Tiempo de trabajo práctico estimado:	3h
Asignatura(s) aplicable(s):	Integración ML Embebido y Edge Computing
Programa(s) Académico(s) / Facultad(es):	Maestría en Automatización y Control Industrial

COMPETENCIAS	CONTENIDO TEMÁTICO	INDICADOR DE LOGRO
Despliegue de modelo de aprendizaje automático detector de objetos.	Adquisición y etiquetado de imágenes. Entrenamiento y prueba de modelos. Despliegue de modelo.	Evaluación de desempeño de modelo entrenado y desplegado en microcontrolador, tarjeta o celular.

2. FUNDAMENTO TEÓRICO

En este proyecto se busca que el estudiante realice el proceso de implementación de un modelo de aprendizaje automático en un dispositivo en el borde. Este proyecto incluye los pasos de: construcción de base de datos, entrenamiento de modelos de aprendizaje automático supervisado (detección de objetos), comparación del desempeño de los modelos entrenados, y evaluación de modelos desplegados. Empezamos definiendo la tarea de detección de objetos.

2.1. Detección de objetos

La detección de objetos es una tecnología de visión artificial que identifica y localiza múltiples elementos en imágenes o videos en tiempo real, dibujando "cuadros delimitadores" (*bounding boxes*) alrededor de ellos. Utiliza redes neuronales convolucionales (CNN) para reconocer patrones, siendo fundamental en vehículos autónomos, seguridad, retail y diagnóstico médico.

A diferencia de la detección de objetos, la clasificación de imágenes envía una imagen completa a través del clasificador para que este genere una etiqueta. Los clasificadores tienen en cuenta la imagen completa, pero no indican dónde aparece la etiqueta en la imagen (ver figura 1).

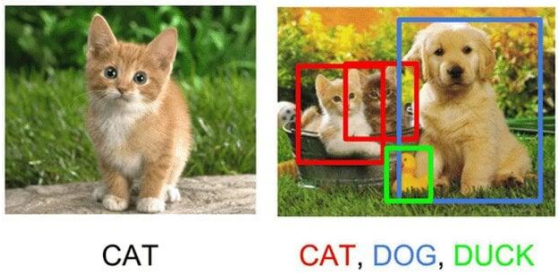

Figura 1. Diferencia entre Clasificación de imágenes con Detección de objetos.

2.2. Evaluación de la detección

Debido que la salida del modelo de detección de objetos es un cuadro delimitador que contiene el objeto, entonces para evaluar el desempeño de los modelos se han propuesto medidas como la intersección sobre la unión (IoU en inglés) entre el cuadro delimitador predicho y cuadro delimitador etiquetado, como se muestra en la figura 2.

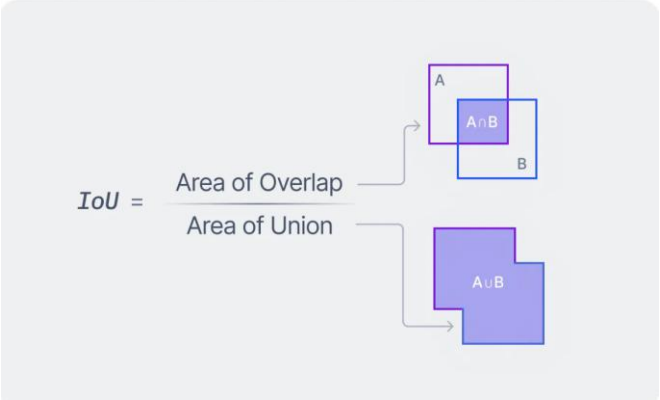

Figura 2. Medida Intersección sobre la Union.

Si el cuadro delimitador de la predicción se aleja del cuadro delimitador de la etiqueta, entonces se obtiene un área pequeña en la intersección y un área grande en la unión, resultando un valor cercano a cero. De lo contrario, si los cuadros delimitadores son muy similares, el área de la intersección es muy similar a la de la unión, resultando en un valor cercano a 1. Finalmente, la media IoU esta definida en el intervalo [0,1], donde valores cercanos a 0 representan una mala detección, y un valor cercano a 1 una buena detección.

2.3. Técnicas de detección de objetos

Existen varias técnicas algunas enfocadas en velocidad y otras en acierto. Uno de los modelos más conocidos es “You Only Look Once” (YOLO). Este modelo lo emplea la plataforma Edge Impulse para automatizar el etiquetado de los objetos en las imágenes. De forma general lo modelos se pueden clasificar en Detectores de una etapa (One-stage), dos etapas (Two-stage), o basados en Transformers.

Los detectores de una etapa son redes neuronales que entrega la caja delimitadora y clase en una sola pasada (Single-shot Detector). Mientras que los detectores de dos etapas primero encuentran las regiones de interés y posteriormente se clasifican y ajustan los cuadros sobre estas regiones de interés. Los detectores de 2 etapas son mas precisos para objetos pequeños y superpuestos, pero requieren mayor costo computacional (ver figura 3).

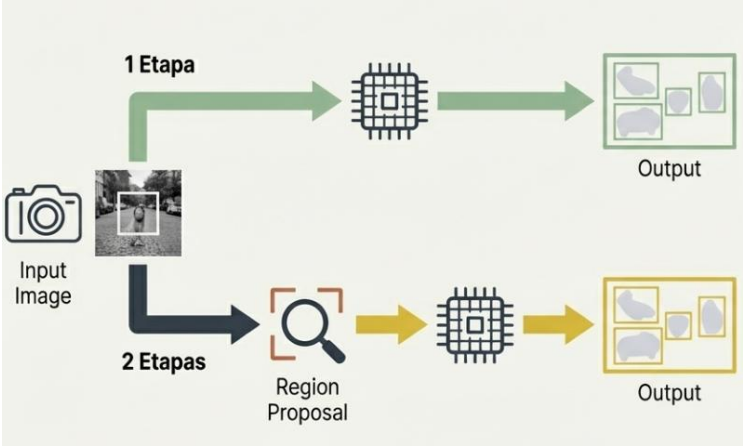

Figura 3. Pasos requeridos por los métodos de una y dos etapas.

En estos últimos años han aparecido modelos basados en redes Transformer como DETR (DEtection TRansformer) desarrollada por Facebook en el 2020. En la figura 4 se muestra una comparativa de los diferentes modelos para los parámetros Velocidad en "Frames Per Second" (FPS)y Precisión en "mean Average Precisión" (mAP).

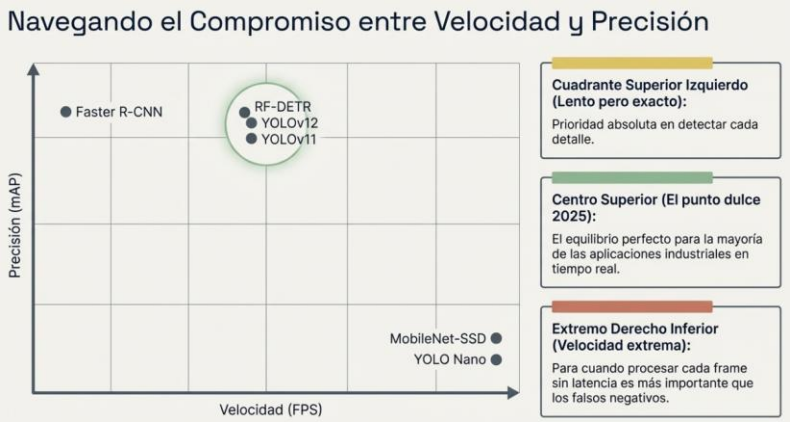

Figura 4. Comparativa de modelos de detección de objetos.

Hasta el momento la plataforma de Edge Impulse solo incluye: MobileNetV2 SSD FPN-Lite (320x320 only), FOMO (Faster Objects, More Objects) MobileNetV2 0.1, FOMO (Faster Objects, More Objects) MobileNetV2 0.35, y YOLO-Pro. Como se puede observar varios modelos emplean la MobileNetV2 para realizar la etapa de extracción de características.

3. OBJETIVO(S)

3.1. Objetivo general

Entrenar y desplegar en un dispositivo en el borde un modelo basado en redes neuronales para detectar objetos en imágenes.

3.2. Objetivos específicos

3.2.1. Construir una base de datos basada en imágenes con varios objetos.
3.2.2. Entrenar un modelo de detección de objetos utilizando redes neuronales.

3.2.3. Desplegar y validar el funcionamiento del modelo en dispositivos en el borde.

4. RECURSOS REQUERIDOS

Plataforma Edge Impulse https://www.edgeimpulse.com/.
Raspberry Pi con Camara, Smart Phone o Nicla Vision.

5. ASPECTOS DE SEGURIDAD

No Aplica.

6. PROCEDIMIENTO O METODOLOGÍA PARA EL DESARROLLO

En esta guía describe los pasos para realizar la clasificación de imágenes utilizando la plataforma Edge Impulse. El primer paso es la adquisición de las imágenes correspondientes a diferentes clases. Luego se procesan y extraen características por medio de un modelo pre entrenado conocido como MobileNet.

6.1. Construcción base de datos

Problema de detección de 3 objetos (por ejemplo, frutas, muebles, cuaderno, lapicero, mouse). Tomar 30 imágenes que contengan los objetos de interés. Existen 2 formas de realizar el proceso de almacenar las imágenes.

1. Se pueden cargar las imágenes junto con las anotaciones utilizando la herramienta “Uploader” de la plataforma Edge Impulse, como se describe en [1].
2. La otra forma es tomar las fotos mientras se está conectado a la plataforma de Edge Impulse por medio del celular. Desde el Dashboard dar clic en “Collect new data”, escanear el código QR y empezar a tomar fotos de los objetos. En el celular seleccionar la opción “Collecting images?” y tomar fotos de cada objeto. **Cuando la plataforma Edge Impulse te pregunte si estas construyendo un proyecto de detección de objetos, como se observa en la figura 3, dar clic en “Yes”**.

Después de almacenar los datos, en la opción del dispositivo objetivo (*Target*), seleccionar Raspberry Pi 4.

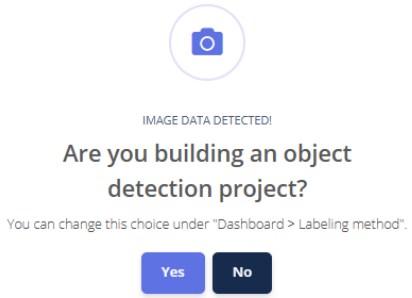

Figura 3. Para clasificación de imágenes selecciona “No”.

Una vez recolectadas las imágenes, procedemos a definir los cuadrados delimitadores de los objetos. En le menú de “Data acquisition” selecciona la pestaña de “Labeling queue”. Aquí podemos delimitar los objetos con cuadrados manualmente. También se puede ejecutar un modelo que realice sugerencias de etiquetas, en la

parte superior derecha la opción "Label suggestions" y seleccionar cual modelo genera las sugerencias de etiquetado. Dar clic en el botón "Save labels" para guardar las anotaciones realizadas sobre la imagen.
Una vez tenemos la base de datos separadas en "Training" y "Test" procedemos a definir el procesamiento de las imágenes hasta la salida del modelo de detección.

6.2. Construcción del Impulso

El diseño del impulse consta de 3 etapas, transformación de las imágenes, análisis de las imágenes, y detección de objetos.

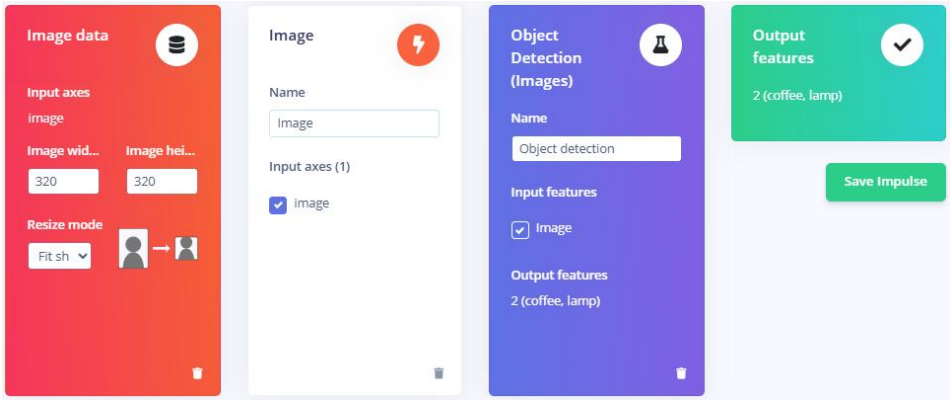

Figura 4. Diseño del impulse para Detección de Objetos.

En el bloque de "Image data" se puede configurar el tamaño de la imagen que entra a la red neuronal de detección de objetos. Se recomienda usar el tamaño 320x320 debido que uno de los modelos de deteccion de objetos solo trabaja con dicha resolución.
En el menú izquierdo seleccionar "Image" observamos como las imágenes originales son reescaladas o recortadas por el bloque de procesamiento de imágenes. Guardar los parámetros y generar las características.

6.3. Entrenamiento de modelo de detección de objetos

En la sección "Object Detection" del menú principal, configuramos cual modelo de detección emplear. Aquí también podríamos activar la opción de "Data augmentation" para generar más muestras para el entrenamiento.
Seleccionamos el modelo MobileNetV2 SSD FPN-line 320x320, y damos clic en "Save & Train".
Observamos cual es el desempeño en mAP, la latencia y el uso de la memoria.

6.4. Evaluación de modelo desplegado

6.4.1. Raspberry Pi

En la Raspberry Pi solo necesitamos tener instalado la interface de comandos de línea, ejecutar:
$ edge-impulse-linux-runner
Y de esta manera nos conectamos a la plataforma, descargamos y evaluamos el modelo generado para el proyecto de clasificación de imágenes.

6.4.2. SmartPhone

En el celular se puede emplear la opción de evaluar el modelo en línea en el menu "Live Classification".

6.4.3. Nicla Vision

Para este microcontrolador se recomienda solo desplegar el modelo FOMO. Revisar la referencia [5].

7. PARÁMETROS PARA ELABORACIÓN DEL INFORME

Comparar los modelos detección de objetos, analizar medidas de desempeño, latencia y uso de la memoria.

8. DISPOSICIÓN DE RESIDUOS

No aplica.

9. BIBLIOGRAFÍA

[1] Object detection with bounding boxes – Edge Impulse. https://docs.edgeimpulse.com/tutorials/end-to-end/object-detection-bounding-boxes.
[2] Object Detection Guide – V7 Labs. https://www.v7labs.com/blog/object-detection-guide.
[3] Object detection – blocks – Edge Impulse. https://docs.edgeimpulse.com/studio/projects/learning-blocks/blocks/object-detection.
[4] Top Object Detection Models for Your Projects in 2025 – DigitalOcean. https://www.digitalocean.com/community/tutorials/best-object-detection-models-guide.
[5] Object detection with nicla vision. https://www.hackster.io/mjrobot/tinyml-made-easy-object-detection-with-nicla-vision-407ddd.

Elaborado por:	*Cristian Guarnizo Lemus*
Revisado por:	
Versión:	*1.0*
Fecha:	*06-03-2026*