1. IDENTIFICACIÓN DE LA GUÍA

Nombre de la guía:	Podado y Cuantificación
Código de la guía (No.):	005
Taller(es) o Laboratorio(s) aplicable(s):	Laboratorio O
Tiempo de trabajo práctico estimado:	9h
Asignatura(s) aplicable(s):	Integración ML Embebido y Edge Computing
Programa(s) Académico(s) / Facultad(es):	Maestría en Automatización y Control Industrial

COMPETENCIAS	CONTENIDO TEMÁTICO	INDICADOR DE LOGRO
Reducción del tamaño de una red neuronal profunda.	Aplica técnicas de podado. Aplica técnicas de cuantificación.	Optimiza el tamaño de una red profunda empleando técnicas de podado y cuantificación.

2. FUNDAMENTO TEÓRICO

En este proyecto se busca que el estudiante realice el proceso compresión o reducción del tamaño de una red neuronal profunda empleando las técnicas de podado y cuantificación. El podado en su versión mas sencilla consiste el eliminar los pesos menos relevantes como se muestra en la figura 1. De esta forma se obtienen representaciones dispersas (muchos ceros) en los tensores o matrices asociadas a los pesos de la red neuronal.

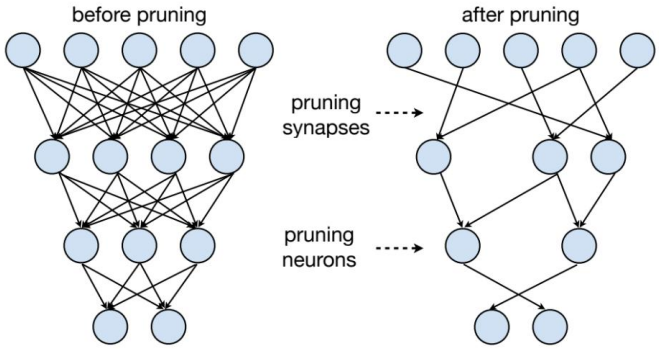

Figura 1. Ejemplo podado.

En la figura 2 se muestra un ejemplo de aplicación sobre un tensor de las técnicas básicas de cuantificación: basada en K-medias, lineal y BitNets. En este caso el objetivo es reducir la representaciones en valores de coma flotante empleando una representación en enteros.

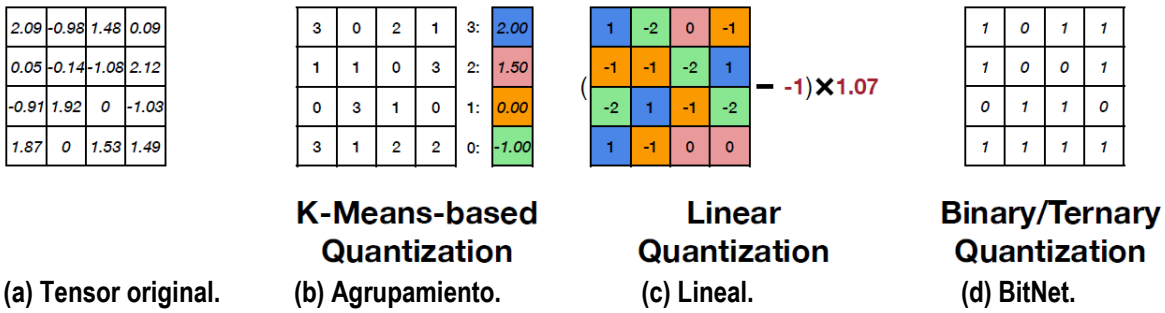

(a) Tensor original. **(b) Agrupamiento.** **(c) Lineal.** **(d) BitNet.**

Figura 2. Tipos de esquema de cuantificación.

Para el caso de basado en las K-medias se logra reducir los tamaños de los tensores por medio de un libro de código de enteros que describe los valores flotantes. La cuantización lineal permite obtener una aproximación de los valores flotantes a partir de valores enteros. Las BitNets son unas redes neuronales donde los pesos solo pueden ser {-1,0,1}. Estas ultimas han mostrado un buen desempeño para modelos grandes de lenguaje.

3. OBJETIVO(S)

3.1. Objetivo general

Reducir el tamaño y la complejidad de una red neuronal profunda empleando técnicas de podado y cuantización.

3.2. Objetivos específicos

3.2.1. Entrenar una red neuronal profunda o emplear un modelo pre-entrenado.
3.2.2. Analizar el desempeño de la red al realizar diferentes factores de podado.
3.2.3. Analizar el desempeño de la red al realizar técnicas de cuantización.
3.2.4. Analizar el desempeño de la red al realizar técnicas de podado y cuantización en conjunto.

4. RECURSOS REQUERIDOS

Librería de TensorFlow para optimización de modelos. https://www.tensorflow.org/model_optimization/guide
Notebooks y presentaciones del curso.

5. ASPECTOS DE SEGURIDAD

No Aplica.

6. PROCEDIMIENTO O METODOLOGÍA PARA EL DESARROLLO

En esta guía describe los pasos para realizar la evaluación de técnicas de compresión u optimización de redes neuronales profundas. Con el fin de evitar que el proyecto sea repetir los notebooks vistos en clase, el estudiante empleara la librería “tensorflow_model_optimization” (https://www.tensorflow.org/model_optimization/guide) de Google, la cual debe explorar, analizar y utilizar para la realización del proyecto.

6.1. Entrenar modelo o usar modelo Pre-entrenado

Se requiere construir un modelo sobre el cual realizar el proceso de optimización con podado y cuantización. El estudiante puede construir un modelo desde cero para un problema en particular, o puede emplear un modelo basado en capas convolucionales y lineales disponibles en https://keras.io/keras_hub/presets/. El modelo debe

ser diferente a los mostrados en los ejemplos de la librería (para MNIST) y preferiblemente orientados para la base de datos ImageNet, como por ejemplo VGG16, VGG19, EfficientNetB7, NASNetLarge, InceptionResNetV2, ResNet152.

6.2. Podado

Estudiar como realizar el podados sobre todo el modelo, sobre algunas capas a partir de la guía de podado disponible en:
https://www.tensorflow.org/model_optimization/guide/pruning/comprehensive_guide.md
https://www.tensorflow.org/model_optimization/guide/pruning/pruning_with_keras

Utilizar la función de podado de baja magnitud "prune_low_magnitude" y programar varios niveles de podado utilizando la función "PolynomialDecay" de Keras para un nivel de dispersión inicial de 0.5 a un nivel final de 0.8. Anotar el desempeño de la red original, de la red podado, y de la red podado y re-entrenada. Graficar la distribución o histograma de los pesos antes y después del podado seleccionado.

6.3. Cuantización

Realizar el entrenamiento sensible a la cuantificación (quantization aware training) para el modelo original de la red entrenada en el ítem 6.1. Estudiar la documentación
https://www.tensorflow.org/model_optimization/guide/quantization/training_example

Realizar el proceso de cuantización y anotar el desempeño de la red original y comparar con la cuantizada.

6.4. Cuantización y Podado

Realizar alguno de los métodos colaborativo que incluye la librería, como CQAT:
https://www.tensorflow.org/model_optimization/guide/combine/cqat_example

7. PARÁMETROS PARA ELABORACIÓN DEL INFORME

Comparar el desempeño y el peso de los diferentes modelos .

8. DISPOSICIÓN DE RESIDUOS

No aplica.

9. BIBLIOGRAFÍA

Model Optimizacion Guide. https://www.tensorflow.org/model_optimization/guide

Elaborado por:	*Cristian Guarnizo Lemus*
Revisado por:	
Versión:	*1.0*
Fecha:	*13-04-2026*