

 Institución Universitaria Reacreditada en Alta Calidad	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	03
		Fecha	18-07-2023

1. IDENTIFICACIÓN DE LA GUÍA

Nombre de la guía:	Destilación del conocimiento
Código de la guía (No.):	007
Taller(es) o Laboratorio(s) aplicable(s):	Laboratorio O
Tiempo de trabajo práctico estimado:	9h
Asignatura(s) aplicable(s):	Integración ML Embebido y Edge Computing
Programa(s) Académico(s) / Facultad(es):	Maestría en Automatización y Control Industrial

COMPETENCIAS	CONTENIDO TEMÁTICO	INDICADOR DE LOGRO
Reducción del tamaño de una red neuronal profunda.	Aplica técnicas de búsqueda de arquitectura.	Optimiza el tamaño de una red profunda empleando técnicas de búsqueda de arquitectura.

2. FUNDAMENTO TEÓRICO

La búsqueda de arquitectura neuronal (NAS) es una técnica empleada para encontrar una arquitectura de manera automática que es direccionada para encontrar el mejor desempeño. Para el caso específico de dispositivos como microcontroladores necesitamos que la arquitectura no solo tenga un buen desempeño sino también que se satisfagan restricciones de latencia, memoria, y espacio de disco.

La búsqueda de una arquitectura de una red neuronal es un proceso muy costoso computacionalmente, debido que, en el peor de los casos para cada arquitectura que se proponga se debe realizar el proceso de entrenamiento de la red neuronal desde cero. En la figura 1 se muestran las componentes principales de la búsqueda de arquitectura neuronal.




Figura 1. Componentes principales de la búsqueda de arquitectura.

	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	03
		Fecha	18-07-2023

Inicialmente se define el espacio de búsqueda, por ejemplo: número de capas, número de neuronas por capa, funciones de activación, tipos de capas, y bloques de celda. Posteriormente, existe diferentes métodos de optimización que realizan la exploración dentro del espacio de búsqueda. Dentro de estos métodos se destacan la búsqueda metaheurística y la optimización Bayesiana. Por último, realizamos la evaluación de las arquitecturas que propone el método de búsqueda. Este último paso es el más costoso computacionalmente, por tal motivo se proponen esquemas de evaluación donde se puede aprovechar el historial de las evaluaciones anteriores para reducir el costo.

3. OBJETIVO(S)

3.1. Objetivo general

Determinar la arquitectura de una red neuronal considerando el hardware empleando técnicas de búsqueda de arquitectura.

3.2. Objetivos específicos

- 3.2.1. Explorar la cantidad de capa, cantidad de neuronas, tipo de función de activación, para una red multicapa en la tarea de clasificación o regresión.
- 3.2.2. Analizar la búsqueda de arquitecturas sobre celdas predefinidas.
- 3.2.3. Analizar el desempeño de las redes propuestas en acierto, tamaño y latencia.

4. RECURSOS REQUERIDOS

La librería Optuna (<https://optuna.org/>) es una plataforma para la búsqueda automática de hiperparámetros.
Tutorial de Optuna: <https://optuna.readthedocs.io/en/stable/tutorial/index.html>.
Tensorflow o PyTorch.
Google Colab.

5. ASPECTOS DE SEGURIDAD

No Aplica.

6. PROCEDIMIENTO O METODOLOGÍA PARA EL DESARROLLO

En esta guía describe los pasos para realizar la búsqueda de arquitecturas de redes neuronales empleando la librería Optuna.

6.1. Espacio de búsqueda

Se propone la posibilidad de poder buscar arquitecturas directamente sobre una red multicapa, como también buscar la combinación de bloques de celdas.

6.1.1. Red neuronal multicapa

Se requiere construir un modelo base sobre el cual se pueda variar la cantidad de capas y neuronas, el tipo de función de activación. También se pueden incluir como parte de la búsqueda los hiperparámetros de tasa de aprendizaje, tamaño del lote, el porcentaje de dropout, método de optimización (Adam, RMSProp), entre otros.

6.1.2. Red basada en bloques de celdas

	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	03
		Fecha	18-07-2023

En este caso permitimos que el modelo pueda tener varias celdas, donde cada celda es una combinación de operaciones de tipo convolucional, max pooling, batch normalization y dropout. Las celdas se pueden construir como parte de la búsqueda de arquitectura, así como también la cantidad de celdas.

6.2. Método de optimización

Para este mini proyecto se propone emplear la librería Optuna como herramienta para realizar la búsqueda de arquitectura. Su esquema principal se basa en métodos bayesianos como “Trees-structured Parzen Estimator” (TPE) orientados a busca de forma eficiente las mejores soluciones.

La librería emplea varios tipos de variables para sugerir soluciones, como son: suggest_float (lineal, con pasos, logarítmico), suggest_int, y suggest_categorical.

6.3. Evaluación

En este trabajo se considera no solo el desempeño de la red propuesta (porcentaje de acierto o error de aproximación) sino también la complejidad de la red, la cual finalmente incurre en la latencia y tamaño del modelo. Optuna cuenta con un ejemplo de optimización multiobjetivo para considerar los FLOPS (operaciones de punto flotante) https://optuna.readthedocs.io/en/stable/tutorial/20_recipes/002_multi_objective.html. En dicho ejemplo, se busca maximizar el “accuracy” y minimizar los FLOPS.

La librería “fvcore” también incluye la función “parameter_count” para considerar el tamaño de la red como una variable a considerar durante el proceso de optimización o búsqueda de arquitectura.

7. PARÁMETROS PARA ELABORACIÓN DEL INFORME

Comparar el desempeño de búsqueda de arquitectura neuronal sobre una base de datos real de imágenes o señales (no usar MNIST o Fashion-MNIST), considerando lo siguiente:

1. Búsqueda de arquitectura de multicapa (con y sin el hiperparametros learning rate).
2. Búsqueda de arquitectura basada en celdas (con y sin el hiperparametros learning rate). Las celdas pueden contener: convolución, max pooling, batch normalization, dropout, y el factor del dropout, el número de canales de salida.
3. Comparar ambas redes.
4. Considerar en el proceso de búsqueda los FLOPS o el tamaño de la red para ambos tipos de red (MLP o Bloques de celdas).
5. Analizar y comparar los resultados obtenidos.

Concluya sobre el trabajo realizado en los procesos de búsqueda de arquitectura.

8. DISPOSICIÓN DE RESIDUOS

No aplica.

9. BIBLIOGRAFÍA

Aaron Klein and Frank Hutter (2019). *Tabular Benchmarks for Joint Architecture and Hyperparameter Optimization*. <https://arxiv.org/abs/1905.04970>

	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	03
		Fecha	18-07-2023

Elaborado por:	<i>Cristian Guarnizo Lemus</i>
Revisado por:	
Versión:	1.0
Fecha:	11-05-2026